

DATA EXPERIENCE

PREDICCIÓN DE FALLAS EN MAQUINARIA INDUSTRIAL

CRISTIAN ALEJANDRO LEON CORDERO

INGENIERIA INDUSTRIAL

DATA EXPERIENCE

21 DE NOVIEMBRE DEL 2026

[github.com-mantenimiento-predictivo-industrial](https://github.com/mantenimiento-predictivo-industrial)



PROBLEMA Y MOTIVACIÓN

Las fallas inesperadas de una máquina pueden generar:


- Paradas no planificadas.
- Pérdida de productividad.
- Costos de reparación.
- Retrasos en la producción.
- Riesgos para la continuidad operativa.

La ciencia de datos puede ayudar a identificar condiciones asociadas con una posible falla y apoyar la planificación del mantenimiento predictivo

Pregunta de investigación

¿ES POSIBLE IDENTIFICAR EL RIESGO DE FALLA DE UNA MÁQUINA UTILIZANDO SUS CONDICIONES OPERATIVAS?

Condiciones operativas –
análisis de datos – alerta de
posible falta



```
{  "gender": "male",  "email": "info@mecanbay.com",  "email_verified_at": null,  "password": "$2y$10$1rmusskiz8Mc.y7H4rxchur3AYT1Baw",  "isActive": 1,  "user_role": "Administrator",  "avatar": null}
```

DATASET UTILIZADO

DATOS UTILIZADOS

Dataset: AI4I 2020 Predictive Maintenance Dataset

Tipo de dataset: Sintético, diseñado para representar un contexto industrial.

Información principal:

- Tipo de producto.
- Temperatura del aire.
- Temperatura del proceso.
- Velocidad de rotación.
- Torque.
- Desgaste de la herramienta.
- Indicador de falla de máquina.



DATASET UTILIZADO

DATOS UTILIZADOS

	id	id_producto	tipo_producto	temperatura_aire	temperatura_proceso	velocidad_rotacion	torque	desgaste_herramienta	falla_maquina	falla_desgaste_herramienta	falla_objetivo
0	1	M14860	M	298.1	308.6	1551	42.8	0	0	0	0
1	2	L47181	L	298.2	308.7	1408	46.3	3	0	0	0
2	3	L47182	L	298.1	308.5	1498	49.4	5	0	0	0
3	4	L47183	L	298.2	308.6	1433	39.5	7	0	0	0
4	5	L47184	L	298.2	308.7	1408	40.0	9	0	0	0

Variable	Descripción
temperatura_aire_c	Temperatura del ambiente
temperatura_proceso_c	Temperatura del proceso
velocidad_rotacion	Velocidad de la máquina
torque	Fuerza de giro
desgaste_herramienta	Desgaste acumulado
falla_maquina	Variable objetivo

Limpieza y preparación de datos

LIMPIEZA Y TRANSFORMACIÓN DE DATOS

Actividades realizadas:

- Revisión de tipos de variables.
- Revisión de valores faltantes.
- Revisión y eliminación de duplicados.
- Eliminación de identificadores.
- Conversión de temperaturas de Kelvin a Celsius.
- Exclusión de variables que podían producir fuga de información.
- Separación de datos para entrenamiento y prueba.

```
duplicados_antes = df.duplicated().
```

```
df = df.drop_duplicates()
```

```
duplicados_despues = df.duplicated()
```

```
print("Duplicados antes de limpiar: 0")
```

```
print("Duplicados después de limpiar: 0")
```

```
Duplicados antes de limpiar: 0
```



```
Duplicados después de limpiar: 0
```

DIVISIÓN DEL DATASET:

80 % ENTRENAMIENTO

20 % PRUEBA

Análisis exploratorio




HALLAZGOS PRINCIPALES:



- La cantidad de registros sin falla es mayor que la cantidad de registros con falla.
- Existe un desbalance entre las clases.
- Por este motivo, la exactitud no debe ser la única métrica de evaluación.
- También deben revisarse la precisión, la sensibilidad, el F1-score y el AUC.

Random Forest



DATOS DE ENTRENAMIENTO: 80%

DATOS DE PRUEBA: 20%

VARIABLE OBJETIVO: FALLA_MAQUINA



CONSTRUCCIÓN DEL MODELO

Modelo utilizado: Bosque aleatorio

¿Por qué se utilizó?

- Permite clasificar máquinas con y sin falla.
- Puede capturar relaciones no lineales.
- Permite analizar la importancia de las variables.
- Es adecuado como modelo inicial para este problema.

RESULTADOS Y EVALUACIÓN




tabla_metricas		
	Métrica	Resultado
0	Exactitud	0.979000
1	Precisión	0.933333
2	Sensibilidad	0.411765
3	F1-score	0.571429
4	AUC	0.964457

La sensibilidad es especialmente relevante porque indica la capacidad para detectar máquinas que realmente presentan una falla.

En mantenimiento industrial, un falso negativo podría provocar una falla no detectada y una parada no planificada.

CONCLUSIONES Y APLICACIÓN PROFESIONAL



En Ingeniería Industrial, este tipo de solución podría apoyar:

- La planificación del mantenimiento.
- La reducción de paradas no planificadas.
- La priorización de inspecciones.
- La mejora de la disponibilidad de los equipos.
- La optimización de recursos de mantenimiento.

- **Conclusiones:**
- Se aplicó un flujo completo de ciencia de datos.
- La limpieza y transformación fueron necesarias antes del modelado.
- El desbalance de clases obligó a revisar varias métricas.
- El modelo puede servir como apoyo para priorizar inspecciones.
- La importancia de una variable no demuestra causalidad.

El dataset es un ejemplo, el modelo debe validarse con datos reales antes de implementarse en una planta industrial.

GRACIAS POR SU ATENCIÓN